



Politechnika Krakowska im. Tadeusza Kościuszki

Wydział Informatyki i Telekomunikacji

PRACA MAGISTERSKA

Zastosowanie fine-tuning'u dużych modeli językowych do wykrywania niechcianej poczty elektronicznej

Title consistent with the topic/field of the thesis

Autor:	Wojciech Drózdź
Kierunek:	Informatyka
Opiekun pracy:	dr inż. Dariusz Żelasko

Kraków, 2026

Tutaj możesz umieścić treść podziękowań. Tutaj możesz umieścić treść podziękowań. Tutaj możesz umieścić treść podziękowań. Tutaj możesz umieścić treść podziękowań.

Streszczenie

Streszczenie po polsku ...

Abstract

Abstract in English . . .

Spis treści

Spis rysunków	xi
Spis tabel	xiii
Lista kodów źródłowych	xvii
1. Spam i co dalej?	1
1.1. Problem niechcianej poczty elektronicznej (spamu)	1
1.1.1. Definicja i rodzaje spamu	1
1.1.2. Skutki spamu i znaczenie jego filtrowania	1
1.2. Duże modele językowe (LLM) w przetwarzaniu języka naturalnego	1
1.2.1. Podstawowe koncepcje LLM	1
1.2.2. Fine-tuning jako metoda adaptacji modeli	1
1.3. Cel i zakres pracy	1
1.3.1. Główny cel badawczy	1
1.3.2. Pytania badawcze	1
1.3.3. Zakres i ograniczenia pracy	1
1.4. Struktura pracy	1
2. Przegląd istniejących metod wykrywania spamu	3
2.1. Tradycyjne metody filtrowania	4
2.1.1. Filtry oparte na regułach	4
2.1.2. Filtry statystyczne (np. Bayesowskie)	4
2.1.3. Listy czarne i białe (Black/White Lists)	4
2.2. Metody oparte na klasycznym uczeniu maszynowym	4
2.2.1. Modele wektorów nośnych (SVM)	4
2.2.2. Drzewa decyzyjne i lasy losowe	4
2.2.3. Inne algorytmy klasyfikacji	4
2.3. Metody oparte na głębokim uczeniu	4
2.3.1. Sieci neuronowe konwolucyjne (CNN) w analizie tekstu	4
2.3.2. Sieci neuronowe rekurencyjne (RNN, LSTM, GRU)	4
2.3.3. Modele oparte na architekturze Transformer (przed erą LLM na dużą skalę)	4

2.4.	Wykorzystanie dużych modeli językowych (LLM) do klasyfikacji tekstu . . .	4
2.4.1.	Podjęcia zero-shot i few-shot	4
2.4.2.	Fine-tuning LLM do zadań specyficznych	4
2.4.3.	Dotychczasowe badania nad LLM w kontekście spamu	4
2.5.	Podsumowanie i identyfikacja luki badawczej	4
3.	Część badawcza	5
3.1.	Wybór otwartoźródłowego modelu językowego	5
3.1.1.	Przegląd dostępnych modeli	5
3.1.2.	Kryteria wyboru modelu	5
3.1.3.	Uzasadnienie wyboru konkretnego modelu	5
3.2.	Metodologia badawcza	5
3.2.1.	Analiza wykorzystanych zbiorów danych	5
3.2.2.	Przygotowanie danych	11
4.	Podsumowanie i wnioski	21
4.1.	Synteza przeprowadzonych badań i uzyskanych wyników	21
4.2.	Odpowiedzi na pytania badawcze	21
4.3.	Wnioski dotyczące skuteczności i praktyczności fine-tuning'u LLM	21
4.4.	Ograniczenia pracy	21
4.5.	Kierunki dalszych badań	21
A.	Typowe elementy składowe pracy dyplomowej z informatyki	23
A.1.	Tabele	23
A.2.	Rysunki	25
A.2.1.	Wewnętrzne	25
A.2.2.	Zewnętrzne	26
A.3.	Kody źródłowe	26
A.4.	Algorytmy	28
A.5.	Wzory	28
A.5.1.	Przykłady	29
A.6.	Twierdzenia i podobne struktury	29
	Uwagi Autora	31
	Bibliografia	33

Zawartość spisu treści — tytuły rozdziałów oraz ich liczba zależą od tematyki pracy — należy ustalić z opiekunem pracy.

Spis rysunków

3.1. Porównanie liczności dostępnych surowych zbiorów danych. Skala pozioma jest logarytmiczna.	7
3.2. Rozkład klas w surowych korpusach. Klasa pozytywna oznacza spam, phishing lub wiadomość oszukańczą.	8
3.3. Udział źródeł w najczęściej używanym zbiorze treningowym.	10
3.4. Liczba rekordów przed deduplikacją oraz po deduplikacji.	13
3.5. Rozmiary grup duplikatów po połączeniu zbiorów danych poza enron	14
3.6. Rozkład długości treści wiadomości według etykiety w analizowanym wariancie danych.	15
3.7. Terminy najsilniej powiązane z klasą pozytywną według wygładzonego ilorazu szans.	16
A.1. Prosty rysunek <i>TikZ</i>	25
A.2. Bardziej złożony rysunek <i>TikZ</i>	25
A.3. Logo Wydziału Informatyki.	26

Spis tabel

3.1. Charakterystyka zbiorów danych	6
3.2. Dostępne kolumny w surowych zbiorach danych oraz sposób ich parsowania .	11
A.1. Pomiary zużycia energii elektrycznej.	23
A.2. Tabela, która zawiera dużą liczbę wierszy.	23
A.3. Tabela zawierająca długi tekst.	24

Lista algorytmów

1. Disjoint decomposition. 28

Lista kodów źródłowych

A.1. Przykładowy kod źródłowy sformatowany za pomocą pakietu 'listings' . . .	27
A.1. Przykładowy listing sformatowany za pomocą pakietu 'minted'	27

3. Część badawcza

3.1. Wybór otwartoźródłowego modelu językowego

3.1.1. Przegląd dostępnych modeli

3.1.2. Kryteria wyboru modelu

3.1.3. Uzasadnienie wyboru konkretnego modelu

3.2. Metodologia badawcza

3.2.1. Analiza wykorzystanych zbiorów danych

Wybór i przygotowanie danych może mieć równie duży wpływ na końcowy wynik jak sama architektura modelu lub wykorzystane parametry treningu.

Jedną z podstawowych części pracy jest więc utworzenie zbioru wiadomości elektronicznych, który zostanie przeznaczony do zadania binarnej klasyfikacji. Wiadomości zostały oznaczone jako pożądane (*ham*, klasa negatywna) lub jako niepożądane (*spam*, klasa pozytywna). Do klasy pozytywnej zostały przypisane wszystkie podkategorie wiadomości niepożądanych takie jak spam, wiadomości oszukańcze, phishingowe lub podejrzane wiadomości marketingowe. Decyzja ta została podjęta głównie ze względu na trudności w znalezieniu dużych zbiorów, które dokonywałyby rozróżnień na poszczególne podklasy.

Korpusy publiczne różnią się nie tylko liczbą rekordów, lecz także sposobem zapisu wiadomości, semantyką etykiet, obecnością metadanych oraz formatem treści. Z tego powodu analiza obejmuje ocenę pochodzenia danych, rozkładu klas, długości wiadomości, obecności duplikatów oraz potencjalnego ryzyka przecieku informacji między częścią treningową i testową.

W pracy przyjęto, że wszystkie zbiory są sprowadzane do wspólnego schematu rekordu: `subject`, `body`, `label` oraz `source`. Pole `subject` przechowuje temat wiadomości, `body` jej treść, `label` wartość liczbową klasy, a `source` nazwę korpusu źródłowego. Taki schemat pozwala porównywać korpusy o różnej strukturze bez wymuszania korzystania z metadanych, które nie występują we wszystkich źródłach.

Do eksperymentów wykorzystano korpusy wymienione w tabeli [3.1](#).


Tabela 3.1.: Charakterystyka zbiorów danych

Zbiór	Wiersze	Ham	Spam	Spam [%]	Uwagi
enron[1]	517 401	517 401	0	0,0	zbiór wiadomości pożądaných, traktowany jako klasa negatywna
trec_2007[2]	75 419	25 220	50 199	66,6	korpus TREC 2007
ceas_2008[3]	39 154	17 312	21 842	55,8	dane CEAS 2008
fraud_email[4]	11 929	6 742	5 187	43,5	
spam_assassin[5]	5 796	3 900	1 896	32,7	
spam_ham[6]	5 171	3 672	1 499	29,0	
fraudulent_email[7] _corpus	3 978	0	3 978	100,0	korpus oszukańczych wiadomości phishingowych zwanych potocznie <i>nigeryjskimi</i> [8]
nazario[9]	3 065	1 500	1 565	51,1	zbiór wiadomości phishingowych
ling[10]	2 893	2 412	481	16,6	

Łącznie analizowane zbiory surowe obejmują 664 806 wiadomości. Nie wszystkie źródła zostały jednak bezpośrednio połączone w jeden korpus treningowy. Największy zbiór, **enron**, zawiera wyłącznie wiadomości klasy negatywnej. Z kolei **fraudulent_email_corpus** zawiera wyłącznie przykłady klasy pozytywnej. Bezpośrednie wykorzystanie wszystkich danych mogłoby oznaczać, że model zamiast uczyć się różnic między treścią spamu i poczty legalnej nauczyłby się rozpoznawać pochodzenie przykładu. Przykładowo, jeśli większość wiadomości legalnych pochodziłaby z jednego archiwum firmowego, a większość wiadomości niepożądanych z innego publicznego korpusu, klasyfikator mógłby wykorzystywać artefakty konkretnego zbioru danych, a nie ogólne cechy spamu. Taki problem jest szczególnie niebezpieczny w eksperymentach z dużymi modelami językowymi, ponieważ modele te potrafią wychwytywać subtelne i nieintencjonalne wzorce formatowania[11].

Rysunek 3.1 pokazuje skalę różnic między korpusami. Połączenie wszystkich danych bez próbkowania prowadziłoby do dominacji zbioru **enron**. Taka dominacja byłaby niepożądana nie tylko ze względu na nierównowagę klas, lecz także ze względu na pochodzenie większości danych *ham* z jednego korpusu.

Rysunek 3.2 przedstawia rozkład klas w źródłowych korpusach. Widoczne są trzy typy zbiorów. Pierwszą grupę tworzą zbiory względnie zbalansowane, takie jak **nazario**, **ceas_2008** oraz **fraud_email**. Drugą grupę tworzą zbiory o wyraźnej przewadze jednej z klas, na przykład **trec_2007**, **ling**, **spam_assassin** i **spam_ham**. Trzecią grupę stanowią korpusy jedno-klasowe: **enron** oraz **fraudulent_email_corpus**. Dla modelowania klasyfikacyjnego najbez-



Rysunek 3.1.: Porównanie liczności dostępnych surowych zbiorów danych. Skala pozioma jest logarytmiczna.

pieczniejsze są zbiory, które zawierają obie klasy i w których rozkład klas nie jest skrajnie zaburzony. Zbiory jednoklasowe mogą być użyteczne jako materiał pomocniczy, ale wymagają ostrożnego łączenia z innymi źródłami, aby nie stworzyć sztucznego zadania rozpoznawania korpusu zamiast rozpoznawania spamu.

Charakterystyka poszczególnych źródeł

ENRON


Zbiór **enron** jest największym z wybranych źródeł danych. Zawiera 517 401 wiadomości, z których wszystkie przynależą do klasy negatywnej. Jego zaletą jest duża liczność i naturalny charakter korespondencji, jednak jednocześnie jest to zbiór specyficzny domenowo. Pochodzi z archiwum organizacyjnego, dlatego może zawierać wiele powtarzalnych struktur, tematów, podpisów, cytowań oraz wątków wewnętrznych. Włączenie go w całości do zbioru treningowego mogłoby sztucznie zwiększyć liczbę przykładów prawdziwej korespondencji, ale niekoniecznie poprawiłoby zdolność modelu do ogólnego rozpoznawania wiadomości pożądaných. Z tego powodu w analizie końcowej nie wybrano wariantu opartego na pełnym zbiorze **enron**.

LING

Zbiór **ling** obejmuje 2 893 rekordy: 2 412 wiadomości pożądaných oraz 481 przykładów klasy pozytywnej. Jest znacznie mniejszy od głównych korpusów, ale ma przejrzysty format z osobnym tematem, treścią i etykietą.

NAZARIO

Zbiór **nazario** obejmuje 3 065 rekordów i jest prawie zbalansowany: 1 500 wiadomości pożądaných oraz 1 565 przykładów klasy pozytywnej. Jego zaletą jest obecność pól tematu,



Rysunek 3.2.: Rozkład klas w surowych korpusach. Klasa pozytywna oznacza spam, phishing lub wiadomość oszukańczą.

treści oraz dodatkowych metadanych, takich jak nadawca, odbiorca, data i adresy URL.

TREC_2007

Zbiór `trec_2007` zawiera 75 419 wiadomości, z czego 50 199 należy do klasy pozytywnej, a 25 220 do klasy negatywnej. Jego zaletą jest relatywnie duża liczność i obecność surowej treści wiadomości. Rozkład klas jest jednak przesunięty w kierunku spamu, który stanowi około 66,6% rekordów.

CEAS_2008

Zbiór `ceas_2008` zawiera 39 154 wiadomości i również ma przewagę klasy pozytywnej, ale jest ona mniejsza niż w `trec_2007`. W zbiorze znajduje się 21 842 wiadomości spamowych oraz 17 312 prawdziwych. Istotną zaletą tego korpusu jest obecność pól takich jak temat, treść, nadawca, odbiorca, data i adresy URL. Dla niniejszej pracy najważniejsze są jednak temat i treść, ponieważ celem jest sprawdzenie możliwości dostrajania modelu językowego do klasyfikacji na podstawie tekstu wiadomości. Obecność adresów URL jest cenna analitycznie, ale nie wszystkie korpusy posiadają to pole, dlatego w podstawowym schemacie zostało ono pominięte.

FRAUD_EMAIL I FRAUDULENT_EMAIL_CORPUS

Zbiory `fraud_email` oraz `fraudulent_email_corpus` dotyczą wiadomości oszukańczych. Pierwszy z nich jest binarny i zawiera 11 929 rekordów, natomiast drugi jest jednoklasowy i zawiera 3 978 wiadomości traktowanych jako klasa pozytywna. Dane te są wartościowe z punktu widzenia semantycznej różnorodności spamu, ponieważ wiadomości oszukańcze mogą

różnić się od typowych reklam farmaceutycznych, newsletterów czy masowego phishingu.

SPAM_ASSASSIN I SPAM_HAM

Zbiory `spam_assassin` i `spam_ham` są mniejsze, ale dobrze pasują do klasycznego zadania klasyfikacji spam/ham. `spam_assassin` zawiera 5 796 rekordów, a `spam_ham` 5 171. W obu przypadkach klasa pozytywna jest mniejszością. Reprezentują inny format i historię przygotowania danych niż korpusy CEAS i TREC użyte w treningu.

Wybór głównego zbioru do eksperymentów


W eksperymentach nie korzystano z jednego niezmiennego wariantu danych. Najczęściej używanym zbiorem treningowym był korpus zbudowany z połączenia wszystkich źródeł poza `enron`, `fraudulent_email_corpus` oraz `spam_ham`. W części eksperymentów stosowano także węższe warianty oparte na zbiorach `trec_2007`, `ceas_2008` albo ich połączeniu. Taki dobór pozwalał sprawdzać zarówno zachowanie modelu na większym, bardziej zróżnicowanym korpusie, jak i na danych pochodzących z bardziej jednorodnych źródeł.

Niektóre zbiory celowo wykluczono z treningu. `enron` pomijano ze względu na bardzo dużą licznosc i jednoklasowy charakter. Jego włączenie mogłoby zdominować klasę negatywną oraz sprawić, że model uczyłby się specyfiki wewnętrznej korespondencji jednej organizacji zamiast ogólnych cech wiadomości legalnych. Z kolei `fraudulent_email_corpus` pozostawiono poza treningiem ze względu na jednoklasowość oraz potrzebę posiadania całkowicie niezależnego zbioru do sprawdzenia generalizacji na wiadomościach oszukańczych. `spam_ham` był traktowany podobnie: jako prosty, zewnętrzny punkt odniesienia dla klasycznego zadania spam/ham.

Po zbalansowaniu najczęściej używany wariant treningowy zawierał 88 054 wiadomości: 44 027 przykładów klasy negatywnej i 44 027 przykładów klasy pozytywnej. Zbiór powstał po usunięciu pustych rekordów, zastosowaniu agresywnej deduplikacji treści oraz próbkowaniu do proporcji 50/50. W składzie źródłowym dominowały `trec_2007` i `ceas_2008`, uzupełnione o `spam_assassin`, `ling` oraz `nazario`.

Rysunek 3.3 pokazuje skład źródłowy najczęściej używanego wariantu treningowego.

Rysunek 3.3 przedstawia skład źródłowy najczęściej używanego zbioru treningowego. Warto zauważyć, że balans klas nie oznacza balansu źródeł. Więcej rekordów pochodzi z `trec_2007` niż z pozostałych korpusów. Pole `source` zostało z tego powodu zachowane w danych analitycznych, aby po treningu możliwe było sprawdzenie wyników oddzielnie dla poszczególnych źródeł. Duża różnica skuteczności między źródłami oznaczałaby ograniczoną odporność na zmianę dystrybucji danych.



Rysunek 3.3.: Udział źródeł w najczęściej używanym zbiorze treningowym.

Zbiór treningowy

Zbiór treningowy służył do aktualizacji parametrów modelu w procesie fine-tuningu i stanowił 80% całego przygotowanego wariantu danych.

Podobnie jak pozostałe podzbiory, był wydzielany dopiero po normalizacji, oczyszczeniu, deduplikacji i balansowaniu wybranego wariantu danych. Dzięki temu każda konfiguracja eksperymentalna korzystała ze spójnego podziału, a ta sama lub bardzo podobna wiadomość nie mogła trafić jednocześnie do zbioru treningowego oraz testowego. Zbiór treningowy zawierał przykłady obu klas w równych proporcjach, ponieważ wcześniej zastosowano balansowanie do relacji 50/50.

Zbiór walidacyjny

Zbiór walidacyjny stanowiący 10% całego zbioru był używany do podejmowania decyzji w trakcie eksperymentów: wyboru liczby epok, konfiguracji hiperparametrów, momentu zatrzymania treningu oraz porównania wariantów promptu lub formatu odpowiedzi. Ponieważ w pracy analizowane są modele językowe, zbiór walidacyjny pełni także rolę praktycznej kontroli formatu generowanej odpowiedzi. Gdy model miał zwracać etykietę w określonej strukturze, na przykład jako tekst `spam/ham` albo obiekt JSON, na zbiorze walidacyjnym sprawdzano, czy odpowiedzi były poprawnie parsowalne.

Zbiór testowy

Zbiór testowy pozostał odseparowany do samego końca eksperymentów i stanowił 10% przygotowanego wariantu danych. Nie był używany do strojenia hiperparametrów ani do podejmowania decyzji w trakcie treningu. Jego rolą była końcowa ocena skuteczności na przykładach pochodzących z tej samej dystrybucji co zbiór treningowy. Oprócz tego model

sprawdzano także na zbiorach nieużywanych w treningu, aby ocenić odporność na zmianę źródła danych.

3.2.2. Przygotowanie danych

Normalizacja schematu

Pierwszym krokiem przygotowania danych było sprowadzenie różnych formatów źródłowych do jednego schematu. Niektóre pliki zawierają osobne kolumny **subject** i **body**; inne przechowują całą wiadomość w jednym polu tekstowym; jeszcze inne mają format zbliżony do surowego e-maila z nagłówkami. Zastosowano strategię pozwalającą zachować maksymalną liczbę przykładów. W przypadku wiadomości surowych wydzielano temat oraz treść. Jeżeli wiadomość była wieloczęściowa, analizowano część tekstową. Jeżeli nie udało się poprawnie sparsować struktury, całą dostępną treść traktowano jako ciało wiadomości.

Drugim elementem normalizacji było ujednolicenie etykiet. W różnych zbiorach klasa pozytywna bywa oznaczana jako **spam**, **1**, **Class=1** albo przez sam fakt pochodzenia z korpusu oszukańczego. W pracy przyjęto konwencję, że **label=1** oznacza wiadomość niepożądaną, phishingową lub oszukańczą, natomiast **label=0** oznacza wiadomość prawdziwą.

Tabela 3.2.: Dostępne kolumny w surowych zbiorach danych oraz sposób ich parsowania

Zbiór	Dostępne kolumny	Sposób parsowania
enron	file, message	Wydzielenie tematu i treści z pola message .
trec_2007	label, origin	Wydzielenie tematu i treści z pola origin .
ceas_2008	sender, receiver, date, subject, body, label, urls	Bezpośrednie mapowanie pól subject , body , label .
fraud_email	Text, Class	Wydzielenie tematu i treści z pola Text .
spam_assassin	text, target	Wydzielenie tematu i treści z pola text .
spam_ham	label, text, label_num	Wydzielenie tematu z prefiksu Subject: .
fraudulent_email_corpus	wiadomości zapisane kolejno z nagłówkami	Wydzielenie tematu z nagłówków i treści z wiadomości.

Zbiór	Dostępne kolumny	Sposób parsowania
nazario	sender, receiver, date, subject, body, label, urls	Bezpośrednie mapowanie pól subject, body, label.
ling	subject, message, label	Przeniesienie message do pola body

Usuwanie pustych rekordów

Po normalizacji odrzucano rekordy z pustym tematem lub pustą treścią. Przykład pozba-
wiony treści albo tematu wnosi niewiele do uczenia, a może wprowadzać artefakty techniczne.
Jeżeli pewien korpus zawierałby dużo pustych rekordów tylko w jednej klasie, model mógłby
nauczyć się, że brak danych jest cechą klasy, co nie byłoby wiarygodną regułą w realnym
wdrożeniu.

Deduplikacja


Deduplikacja to kluczowy etap przygotowania danych, który zapobiega przeciekowi infor-
macji między zbiorem treningowym a testowym. Bez tego modele językowe o dużej pojem-
ności mogłyby zapamiętywać powtarzające się wiadomości zamiast uczyć się ogólnych reguł
klasyfikacji.

W pracy zastosowano kilkuwarstwową metodę wykrywania duplikatów, opartą na porów-
naniu tematu, treści i etykiety wiadomości. Przed porównaniem tekst normalizowano: usu-
wano białe znaki, tagi i encje HTML, adresy URL, e-maile oraz znaki niealfanumeryczne.
Zastosowano również konwersję na małe litery oraz normalizację Unicode. Krok ten jest nie-
zbędny, ponieważ publiczne zbiory e-mailowe często różnią się jedynie drobnymi szczegółami
formatowania, nagłówkami lub linkami śledzącymi.

W tej części analizowano zbiór utworzony z połączenia wszystkich źródeł poza **enron**. Po
normalizacji otrzymano 147 405 rekordów. Następnie odrzucono 20 766 wiadomości z pustym
tematem lub pustą treścią, pozostawiając 126 639 przykładów do deduplikacji. Deduplikacja
na poziomie **high** wykryła 5277 grup duplikatów i usunęła 26 883 nadmiarowe rekordy. Po
tym etapie pozostało 99 756 wiadomości. Mediana rozmiaru grupy duplikatów wyniosła 2, a
największa grupa zawierała 2618 wiadomości.


Rysunek 3.4 zestawia dwa poziomy analizy: osobne korpusy źródłowe oraz zbiór połączony
ze wszystkich źródeł poza **enron**. Dzięki temu widać zarówno wpływ deduplikacji na dane
używane do dalszego łączenia, jak i skalę powtórzeń w poszczególnych źródłach. Największą
różnicę widać w osobno pokazanym zbiorze **enron**. Jest to korpus poczty z jednej firmy, w
którym ta sama wiadomość mogła trafić do wielu odbiorców, tworząc dużą liczbę powtórzeń.

Rysunek 3.5 pokazuje, że większość grup duplikatów jest niewielka. Jest to typowe dla
korpusów e-mailowych: część wiadomości występuje dokładnie lub prawie dokładnie dwa



Rysunek 3.4.: Liczba rekordów przed deduplikacją oraz po deduplikacji.

razy, natomiast bardzo duże grupy są rzadsze. Ze względu na długi ogon rozkładu większe grupy zostały połączone w przedziały. Nawet niewielkie grupy są jednak istotne, ponieważ przy losowym podziale danych mogłyby zostać rozdzielone między trening i test.



Rysunek 3.5.: Rozmiary grup duplikatów po połączeniu zbiorów danych poza **enron**.


Balansowanie klas

Po oczyszczeniu i deduplikacji zastosowano balansowanie klas do proporcji 50/50. Po deduplikacji zbiór utworzony ze wszystkich źródeł poza **enron** zawierał 51 296 wiadomości legalnych oraz 48 460 wiadomości niepożądanych. Balansowanie usunęło więc jedynie nadmiar przykładów z klasy negatywnej. Po balansowaniu zbiór ten zawierał 96 920 rekordów: 48 460 wiadomości pozytywnych i 48 460 negatywnych. Dzięki temu metryka dokładności staje się łatwiejsza do interpretacji, ponieważ klasy mają równy udział. Model nie jest też zachęcany do preferowania klasy większościowej. Porównanie wariantów eksperymentalnych jest stabilniejsze, ponieważ zmiany wyników nie wynikają z przypadkowego przesunięcia proporcji klas.

Balansowanie ma jednak również ograniczenia. Rzeczywisty strumień poczty użytkownika nie będzie zbalansowany. W większości środowisk spam może stanowić mały procent wiadomości, w innych znacznie większy. Dlatego wyniki na zbiorze zbalansowanym należy interpretować jako ocenę zdolności rozróżniania klas, a nie bezpośrednią symulację produkcyjnego rozkładu wiadomości.

Analiza długości wiadomości

Długość wiadomości jest ważną cechą danych, ponieważ wpływa na koszt przetwarzania przez model językowy, dobór maksymalnej liczby tokenów oraz potencjalne ucinanie wejścia. W analizowanym wariancie mediana długości treści wynosi 162 słowa, natomiast 95. percentyl wynosi 1025 słów. Oznacza to, że większość wiadomości mieści się w umiarkowanym limicie kontekstu, ale istnieje istotna grupa długich wiadomości. Jeżeli model ma ograniczony maksymalny kontekst, zbyt krótkie obcięcie treści mogłoby usuwać informacje ważne dla klasyfikacji.



Rysunek 3.6.: Rozkład długości treści wiadomości według etykiety w analizowanym wariancie danych.


Rysunek 3.6 pokazuje różnice długości między klasami. Wiadomości legalne mają medianę 212 słów, pierwszy kwartył 120 słów, trzeci kwartył 406 słów i 95. percentyl 1399 słów. Wiadomości spamowe są krótsze: mediana wynosi 101 słów, pierwszy kwartył 41 słów, trzeci kwartył 277 słów, a 95. percentyl 699 słów. Krótsza treść może wynikać z charakteru analizowanych kampanii spamowych, ale w innych zbiorach spam może być dłuższy, na przykład w wiadomościach oszukańczych typu *advance-fee fraud*[12].

Analiza według źródeł ujawnia dodatkowe różnice. W `ceas_2008` wiadomości legalne mają medianę 201 słów, a spam jedynie 40 słów. W `trec_2007` wiadomości legalne mają medianę 224 słowa, natomiast spam 147 słów. W `fraudulent_email_corpus` mediana wiadomości pozytywnych wynosi 452 słowa, a w `spam_assassin` spam ma medianę 386 słów. Oznacza to, że różnica długości między klasami nie jest stabilną właściwością samego problemu, lecz zależy od źródła danych. Model może wykorzystywać tę informację, co negatywnie wpłynie na jego realną skuteczność. Jeżeli klasyfikator opierałby się głównie na długości, generalizacja

do nowych typów spamu mogłaby być ograniczona.

Analiza słownictwa

Dodatkowo przeprowadzono prostą analizę słów najbardziej powiązanych z klasą pozytywną i negatywną. Ranking oparto na wygładzonym ilorazie szans liczonym dla tokenów występujących w temacie i treści wiadomości. Wśród terminów silnie związanych ze spamem pojawiają się między innymi `anatrim`, `canadianpharmacy`, `usaa`, `producttestpanel` oraz `billyboy`. Część z nich odpowiada klasycznym kampaniom reklamowym i farmaceutycznym, a część odzwierciedla konkretne źródła wiadomości phishingowych. Z kolei wśród terminów powiązanych z wiadomościami legalnymi pojawiają się między innymi `theweathernetwork`, `accuweather`, `reproducible`, `speakup` oraz `cbsnews`.



Rysunek 3.7.: Terminy najsilniej powiązane z klasą pozytywną według wygładzonego ilorazu szans.

Rysunek 3.7 wskazuje, że wysoka pozycja słów farmaceutycznych potwierdza, że część spamu w korpusie ma charakter reklamowy. Jednocześnie obecność bardzo specyficznych tokenów pokazuje ryzyko uczenia się artefaktów zbioru. Duży model językowy może poprawnie klasyfikować takie wiadomości, ale dobra skuteczność na korpusie zawierającym powtarzalne

słowa kampanii nie musi automatycznie oznaczać odporności na nowy, bardziej wyrafinowany phishing.

Bibliografia

- [1] *Enron Email Dataset*. URL: <https://www.kaggle.com/datasets/wcukierski/enron-email-dataset> (term. wiz. 27.05.2026).
- [2] *Emails for Spam or Ham Classification TREC 2007*. URL: <https://www.kaggle.com/datasets/bayes2003/emails-for-spam-or-ham-classification-trec-2007> (term. wiz. 27.05.2026).
- [3] *CEAS 08*. URL: <https://www.kaggle.com/datasets/doryanay/ceas-08> (term. wiz. 27.05.2026).
- [4] *Fraud Email Dataset*. URL: <https://www.kaggle.com/datasets/llabhishek11/fraud-email-dataset> (term. wiz. 27.05.2026).
- [5] *Spam Assassin Email Classification Dataset*. URL: <https://www.kaggle.com/datasets/ganiyuolalekan/spam-assassin-email-classification-dataset> (term. wiz. 27.05.2026).
- [6] *Spam Mails Dataset*. URL: <https://www.kaggle.com/datasets/venky73/spam-mails-dataset> (term. wiz. 27.05.2026).
- [7] *Fraudulent Email Corpus*. URL: <https://www.kaggle.com/datasets/rtatman/fraudulent-email-corpus> (term. wiz. 27.05.2026).
- [8] Farooq A. Kperogi. „Your English Is Suspect”: Language, Communication, and the Pathologization of Nigerian Cyber Identity Through the Stylistic Imprints of Nigerian E-Mail Scams”. W: *Sage Journals* 42.1 (2018).
- [9] *Nazario 5 Datatest*. URL: <https://www.kaggle.com/datasets/zeyadkarimfcai/nazario-5-datatest> (term. wiz. 27.05.2026).
- [10] *Ling-Spam Dataset*. URL: <https://www.kaggle.com/datasets/mandygu/lingspam-dataset> (term. wiz. 27.05.2026).
- [11] Mengnan Du i in. „Shortcut Learning of Large Language Models in Natural Language Understanding”. W: *arxiv* 1.3 (2022).
- [12] *Advance Fee Fraud*. URL: <https://www.investor.gov/protect-your-investments/fraud/types-fraud/advance-fee-fraud>.