

Streszczenie

Praca dotyczy dostrajania małych modeli językowych z otwartymi wagami do binarnej klasyfikacji wiadomości jako pożądane albo niepożądane. Po przeglądzie dostępnych modeli do badań wybrano Qwen3-0.6B. Wykorzystano metodę niskorangowej adaptacji LoRA. Porównano 16 konfiguracji oraz stany modelu zapisane w kolejnych etapach treningu. Następnie sprawdzono cztery sposoby użycia modelu jako klasyfikatora. Porównanie objęło także model bez dostrajania i sześć innych klasyfikatorów. Kończącą ocenę przeprowadzono na czterech rozłącznych zbiorach testowych, obejmujących po 2000 wiadomości. Na czterech zbiorach testowych najlepszy dostrojony wariant osiągnął średnią dokładność klasyfikacji równą 97,8%. DistilBERT, najszybszy z pozostałych klasyfikatorów, osiągnął średnią dokładność 94,4% i działał około 2,3 raza szybciej od Qwen3. Zastosowanie dostrojonego modelu w filtrze poczty wymaga uwzględnienia kosztu obliczeniowego klasyfikacji i sprawdzenia go na bieżącym ruchu pocztowym.

Słowa kluczowe: niechciana poczta elektroniczna, klasyfikacja spamu, modele językowe, Qwen3, LoRA